

《离线 AI 助手》 产品需求文档

产品名称 离线 AI 助手

版本号 v1.0 状态 开发中

编写人 快点逃跑啊

更新时间 2026-06-21

1. 产品概述

1.1 产品简介

离线 AI 助手是一款面向设备维修技术人员的 Android 本地智能诊断应用。用户导入产品维修手册（PDF/TXT）后，应用基于本地大语言模型进行检索增强生成（RAG）问答。所有计算在设备本地完成，无需网络连接。

1.2 核心价值

- 完全离线：模型与数据均在本地，适用于无网络覆盖的维修现场
- 数据安全：手册内容不上传云端，敏感技术文档不外泄
- 精准溯源：诊断建议引用手册原文编号，可追溯验证
- 即装即用：首次启动自动解压模型，冷启动时间小于 5 秒

2. 市场与问题分析

2.1 目标市场

市场	说明	网络环境
工业设备售后维修	工厂、工地等现场维修场景	车间/地下室无信号
野外勘探与地质调查	地质队、石油勘探等野外作业	深山荒漠完全无网
户外运动与应急救援	登山、探险、救援队	偏远山区无覆盖
医疗设备维护	医院设备科	内网隔离

2.2 用户痛点

痛点	频次	严重程度
现场维修无网络，无法查阅电子手册	高频	高
野外/偏远地区完全无网，无法获取技术信息	高频	高
纸质手册检索缓慢	高频	中
维修人员依赖经验，缺乏系统指导	中频	高
内部敏感文档不能上传云端	中频	高

2.3 现有方案对比

方案	离线可用	检索效率	数据安全	成本
纸质手册	是	低	是	印刷成本
手机拍照存档	是	低	是	低
在线 AI 知识库	否	高	否	月费
离线 AI 助手	是	高	是	一次性

3. 产品定位与目标

3.1 产品定位

面向无网络和涉密场景的本地 AI 知识库工具。用户导入 PDF 手册后，在完全离线的环境下获得基于原文的精准问答，适用于设备维修、野外作业、应急救援、涉密内网等场景。

3.2 产品目标

目标一：打造可用的离线 RAG 问答体验 - RAG 检索 Top-5 准确率不低于 85% - 回答引用可追溯至原文 - 单次推理端到端延迟不超过 120 秒（2B 模型）

目标二：降低使用门槛 - 首次启动时间不超过 40 秒 - PDF 导入至可查询时间不超过 30 秒 - 新用户首次问答成功率不低于 80%

目标三：确保稳定可靠 - 应用崩溃率低于 0.1% - 模型加载成功率不低于 99% - 无内存溢出导致的应用退出

4. 用户画像与场景

4.1 用户画像

维度	画像一：维修工程师	画像二：户外工作者	画像三：设备科负责人
年龄	25 - 40 岁	28 - 45 岁	35 - 55 岁
职业	工厂/工地设备维修	地质勘探、野外救援、户外领队	医院设备管理
设备	Android 中高端手机	三防/户外 Android 手机	Android 手机
网络环境	车间/地下室无信号	深山/荒漠/海上完全无网	内网隔离
核心痛点	现场查手册需回办公室	遇故障/紧急情况无网络可查	数据不能出内网
使用习惯	问题导向，随问随查	提前导入，应急查询	合规使用，需审计

4.2 典型场景

场景	用户	触发条件	使用流程	成功标准
首次配置	新用户	安装后首次打开	安装 APK -> 启动 -> 自动解压模型 (约 25s) -> 进入主页	40 秒内进入主页
导入手册	所有用户	获取新手册 PDF	点击导入 -> 选择 PDF -> 进度显示 -> 完成	100 页 PDF 30 秒内完成
设备故障诊断	维修工程师	现场设备故障	输入故障现象 -> RAG 检索 -> AI 给出带引用的诊断	回答准确引用原文
野外应急查询	户外工作者	野外遇险/设备故障	打开 APP -> 输入问题 -> 离线推理 -> 获取指导	无需网络完成全流程
涉密环境使用	设备科负责人	内部审计/维修	在内网环境正常使用所有功能	数据不产生任何外发

4.3 场景详解

场景一：野外求生应急查询

用户携带装载离线知识库（如野外生存手册、急救指南、装备说明书）的 Android 手机进入无信号区域。遇突发情况时，打开应用输入问题（如“被蛇咬伤如何处理”“岩壁下降绳索固定方法”），应用在完全离线状态下完成检索和推理，返回基于手册原文的指导。

此场景对产品的核心要求： - 零网络依赖，所有功能在飞行模式下正常运行 - 知识库支持用户自行导入任何 PDF 格式的野外生存手册或技术文档 - 响应结果必须引用原文，便于用户在紧张情况下核对原始资料

场景二：地质勘探现场技术支援

地质勘探人员在偏远山区作业，随身携带离线知识库（含勘探设备手册、地质标准规范、安全操作规程）。遇到设备故障或需要查阅技术规范时，即时提问获取答案。

场景三：应急救援现场信息查询

救援人员在灾害现场使用 APP 查询救援设备操作规范、急救流程等信息。现场通常无网络覆盖，且需要快速精确的信息检索。

场景四：户外运动领队行程保障

户外领队在带队前导入相关路线指南、安全手册、天气预报判读指南等资料。行程中遇到问题可随时查询，确保团队安全。

5. 系统架构

5.1 架构分层

表现层：Android Jetpack Compose + Material 3 - SplashScreen：启动引导与加载进度 - HomeScreen：底部 Tab 导航（诊断/手册） - ChatScreen：对话界面 - ManualScreen：知识库管理界面

应用层：Kotlin - ChatRepository：对话记录管理（Room 数据库） - Retriever：RAG 编排（文档处理、向量索引、检索）

推理层：Kotlin + JNI - ModelManager：模型解压、加载、生命周期管理 - InferenceService：Prompt 构建、输出清洗、免责声明

原生层：C++（NDK） - llama-jni.cpp：JNI 桥接 - llama.cpp：Qwen3.5-2B 推理引擎 - BGE-small-zh：Embedding 模型

5.2 数据流

导入流程：PDF/TXT -> 文本提取 -> 句子切分 -> 重叠分块 -> BGE Embedding -> 索引持久化

问答流程：用户输入 -> BGE Query Embedding -> 余弦相似度检索 -> Top-5 分块 -> 句子窗口扩展 -> 模型推理 -> 输出清洗 -> 展示

5.3 技术栈

层级	技术	版本
推理引擎	llama.cpp	master
生成模型	Qwen3.5-2B Q4_K_M GGUF	2B
Embedding	BGE-small-zh v1.5 Q4_K_M	512 维
UI	Jetpack Compose + Material 3	BOM 2024.04
本地存储	Room (SQLite) + 自定义二进制格式	Room 2.6.1
最低 SDK	Android 8.1 (API 26)	targetSdk 34
构建	Gradle 8.5 + AGP 8.2.2 + CMake 3.22.1	NDK 26.x

6. 功能需求

6.1 功能清单

编号	模块	功能	优先级	状态
F01	启动	首次启动自动解压模型	P0	已完成
F02	启动	加载进度展示	P0	已完成
F03	启动	冷启动小于 5 秒	P1	已完成
F04	知识库	PDF 导入	P0	已完成
F05	知识库	TXT 导入	P1	已完成
F06	知识库	文件管理（查看/删除）	P0	已完成

编号	模块	功能	优先级	状态
F07	知识库	导入进度显示	P1	已完成
F08	知识库	Embedding 模型就绪检查	P1	已完成
F09	问答	RAG 检索问答	P0	已完成
F10	问答	编号引用来源输出	P0	优化中
F11	问答	对话历史记录	P1	已完成
F12	问答	清空对话	P1	已完成
F13	问答	空状态引导	P1	已完成
F14	问答	Think 标签自动清理	P1	已完成
F15	主题	深色/浅色自适应	P2	已完成

6.2 需求详情

F01-F03：启动流程

应用启动后自动加载本地模型。首次使用时将 GGUF 模型从 assets 解压到应用私有目录，后续启动直接加载已解压文件。

状态流转：IDLE 进入 EXTRACTING（解压中）进入 LOADING（加载中）进入 READY（就绪）或 ERROR（错误）

验收标准

验收项	要求
首次启动耗时	解压模型至就绪，不超过 40 秒
冷启动耗时	已解压模型加载至就绪，不超过 5 秒
错误处理	加载失败时展示错误原因和重试按钮

F04-F08：知识库管理

用户通过系统文件选择器导入 PDF 或 TXT 文件，系统自动提取文本、切分句子、构建重叠分块、生成向量索引。

验收标准

验收项	要求
格式支持	PDF 和 TXT
导入进度	分三阶段：文本提取（5%-20%）、句子切分（20%-35%）、向量索引（35%-100%）
导入结果	显示文件名称和分块数量
文件管理	支持长按多选删除，删除前需确认
前置检查	Embedding 模型未就绪时提示用户

限制条件

限制项	说明
文档长度上限	单文档最多 2000 句
PDF 类型	仅支持文字型 PDF，不支持扫描件 OCR
TXT 编码	优先 UTF-8，回退 GBK

F09-F14：问答

用户输入问题后，系统检索知识库相关内容，基于 RAG 生成带原文引用的回答。

验收标准

验收项	要求
有知识库	基于参考资料回答，附加来源编号
无知识库	提示请先导入手册文档
未找到内容	回复未找到相关信息
免责声明	回答末尾自动追加
Think 标签	输出中的推理过程标签自动清理

7. AI 模型行为规范

7.1 模型角色定义

维度	定义
角色	文档检索机器人
能力边界	仅能回答知识库手册中包含的内容
禁止行为	使用外部知识、编造信息、提供个人建议
输出语言	中文

7.2 推理参数

参数	值
生成模型	Qwen3.5-2B Q4_K_M
Embedding 模型	BGE-small-zh v1.5 Q4_K_M
上下文窗口	2048 tokens
最大生成 tokens	1024
采样策略	Greedy
CPU 线程数	自动检测（当前小米 14 测试机 8 线程中的 7 个）

7.3 已知失败模式及应对

失败模式	表现	应对措施
Think 标签溢出	模型输出 <think> 推理过程消耗 token 预算	正则检测并清理 think 块
Think 标签不闭合	<think> 无对应 </think>	回退提取答案标记或保留生成内容尾部
回答偏离参考资料	模型使用训练知识而非文档内容	强制 system prompt + 参考资料置于 user 消息
输出格式偏离	未按要求输出来源引用	待优化（加强 prompt 示例）
Token 截断	超过 maxTokens 导致回答不完整	设置 1024 token 上限

7.4 提示词设计

System Prompt:

你是严格的文档检索机器人。
规则：只使用【参考资料】中的原文回答。必须引用编号来源。
如果参考资料无相关内容，只回复：根据提供的资料，未找到相关信息。
直接给出最终答案。禁止思考推理过程。

User Message 格式:

【参考资料】
[1] 《文档名》(位置百分比) 原文内容...
[2] 《文档名》(位置百分比) 原文内容...

问题：{用户输入}

8. RAG 检索策略

8.1 技术方案

采用句子级重叠分块 + 窗口扩展检索策略。

8.2 分块策略

原始文本按中文标点断句后，以 N 句为一组构建分块，相邻分块间重叠 M 句。

参数	值	说明
CHUNK_SENTENCES	3	每个分块包含 3 个句子
OVERLAP_SENTENCES	1	相邻分块重叠 1 个句子

示例（S 表示句子）：

分块	内容	说明
Chunk 0	S0 S1 S2	起始块
Chunk 1	S1 S2 S3	与 Chunk 0 重叠 S1、S2
Chunk 2	S2 S3 S4	与 Chunk 1 重叠 S2、S3

8.3 检索流程

步骤	操作	说明
1	查询向量化	BGE Query Embedding，加检索前缀指令
2	相似度计算	余弦相似度遍历全部分块
3	Top-5 筛选	取相似度最高的 5 个分块
4	窗口扩展	每个命中分块前后各取 4 个句子
5	结果聚合	去重、拼接、格式化为参考资料

8.4 持久化格式

文件	格式	内容
chunks.json	JSON	分块元数据（文本、句索引范围、来源文件）
sentences.json	JSON	句子列表（用于窗口重建）
embeddings.bin	二进制	浮点向量数组，5 字节头部（版本号+维度）

9. 非功能需求

9.1 性能

指标	目标
首次启动耗时	不超过 40 秒
冷启动耗时	不超过 5 秒
单次推理耗时	不超过 120 秒
Prompt 处理耗时	不超过 5 秒

指标	目标
RAG 检索耗时	不超过 500 毫秒
PDF 导入耗时（100 页）	不超过 30 秒
Release APK 大小	不超过 1.5 GB

9.2 内存

项目	说明
最大 RSS	不超过 2.5 GB
模型常驻内存	约 1.5 GB（2B Q4）+ 200 MB（BGE）+ 50 MB（应用）
最低设备要求	4 GB RAM，推荐 6 GB 以上
保护措施	已在 Manifest 中启用 largeHeap

9.3 存储

项目	说明
模型文件	约 1.3 GB（Qwen2B）+ 15 MB（BGE）
向量索引	约 1 KB 每句
总占用	约 1.4 GB 外加手册文件

9.4 安全

项目	说明
网络权限	Manifest 无 INTERNET 权限
数据存储	完全在应用私有目录
文件校验	模型文件解压后校验大小完整性

9.5 兼容性

项目	要求
最低 Android 版本	8.1（API 26）
目标 Android 版本	14（API 34）
CPU 架构	arm64-v8a
最低 RAM	4 GB（推荐 6 GB）

10. 成功指标

10.1 北极星指标

单次问答准确率：用户获得的可验证正确回答次数占总提问次数的比例不低于 85%。

10.2 核心指标

指标	定义	当前	目标
检索准确率	Top-5 包含正确答案的比例	约 75%	不低于 85%
引用准确率	回答与引用来源一致的比例	待测	100%
端到端延迟	提问到显示回答的时间	约 130 秒	不超过 120 秒
导入成功率	PDF 导入成功的比例	待测	不低于 95%
无崩溃会话率	无异常退出会话占比	待测	不低于 99.9%

10.3 监测方式

方式	说明
日志采集	通过 adb logcat 采集检索评分、推理耗时、token 计数
用户反馈	后续版本加入匿名使用统计

11. 路线图

版本	阶段	内容	预计时间
v1.0	已完成	基础 RAG 问答、PDF/TXT 导入、知识库增删管理、对话历史存储、深色/浅色主题	当前版本
v1.1	优化中	Think 标签清理、来源引用格式输出、System prompt 迭代、KV cache 复用优化、Token 预算调优	近期
v1.2	规划中	流式输出、推理速度优化、多轮对话支持、批量导入、文档搜索	中期
v1.3	远期规划	混合检索（dense + sparse）、OCR 支持、对话导出、模型版本切换、GPU 加速（Vulkan）	远期
v2.0	企业版	多用户管理、工单系统集成、云端同	远期

版本	阶段	内容 步（可选）、品牌 定制、审计日志	预计时间
----	----	---------------------------	------

12. 风险评估

风险	概率	影响	应对措施
模型幻觉	中	高	强制引用来源、system prompt 约束、输出后校验
推理速度慢	高	中	当前 130 秒为物理限制，后续通过 GPU 加速改善
APK 体积过大 (1.4 GB)	高	中	应用商店支持大文件上传，可考虑 AAB 格式
低内存设备崩溃	中	高	已启用 largeHeap, 4 GB 设备建议降级 0.8B 模型
PDF 解析失败	中	中	仅支持文字 PDF，不支持扫描件
Embedding 模型加载失败	低	高	加载后执行 test embedding 验证
模型文件损坏	低	高	解压后校验文件大小

13. 附录

13.1 术语表

术语	说明
RAG	Retrieval-Augmented Generation, 检索增强生成
GGUF	llama.cpp 使用的模型格式
Q4_K_M	4-bit 量化方式
BGE	BAAI General Embedding, 通用向量模型
Chunk	文本分块, 索引和检索的最小单元
KV Cache	Transformer 注意力计算中的键值缓存
JNI	Java Native Interface, Kotlin 调用 C++ 的桥梁
NDK	Android Native Development Kit

13.2 项目文件结构

```
OfflineAI/
PRODUCT_DOCUMENT.md
README.md
build.gradle.kts
settings.gradle.kts
gradle.properties
app/
```

build.gradle.kts
proguard-rules.pro
src/main/
AndroidManifest.xml
cpp/
CMakeLists.txt
llama-jni.cpp
assets/
res/
java/com/offlineai/app/
OfflineAIApp.kt
MainActivity.kt
engine/
LlamaBridge.kt
ModelManager.kt
InferenceService.kt
rag/
DocumentProcessor.kt
VectorStore.kt
Retriever.kt
data/
AppDatabase.kt
ChatRepository.kt
ui/
theme/
Color.kt
Theme.kt
screens/
SplashScreen.kt
HomeScreen.kt
ChatScreen.kt
ManualScreen.kt